



# **Exercice de programmation n°1 :**

## **Régression Linéaire**

GAO BIN  
11/11/2016

# Introduction

Dans ce TP, on commence par télécharger le Octave et on améliore le code pour bien marche.

## 1. Simple octave function

Dans cette exercice, on ajoute le code `A=eye(5)` dans le fichier `warmUpExercise.m`

```
1 function A = warmUpExercise()
2 %WARMUPEXERCISE Example function in octave
3 % A = WARMUPEXERCISE() is an example function that returns the 5x5 identity matrix
4
5
6 % ===== YOUR CODE HERE =====
7 % Instructions: Return the 5x5 identity matrix
8 % In octave, we return values by defining which variables
9 % represent the return values (at the top of the file)
10 % and then set them accordingly.
11
12
13 A=eye(5);
14
15
16
17
18 % =====
19
20
21 end
```

Après, pour observer les résultats de modifications, on tape `<<ex1.m>>` et on fait `run ex1.m` dans la `<<fenêtre de commande>>`, on peut obtenir une matrice 5x5 identité.

```
25 %% ===== Part 1: Basic Function =====
26 % Complete warmUpExercise.m
27 fprintf('Running warmUpExercise ... \n');
28 fprintf('5x5 Identity Matrix: \n');
29 warmUpExercise()
30
```

Le résultat :

```
Running warmUpExercise ...
5x5 Identity Matrix:
ans =

Diagonal Matrix

    1    0    0    0    0
    0    1    0    0    0
    0    0    1    0    0
    0    0    0    1    0
    0    0    0    0    1

Program paused. Press enter to continue.
```

Ci-dessus on appelle `<<warmUpExercise>>`. Si vous voulez quitter, taper `ctrl-c` va arrêter le programme.

## 1.1 Submitting Solutions

Après avoir terminé la première partie de l'exercice, on peut aller sur l'objectif et puis on peut améliorer le code pour arriver à la régression linéaire des points donnés, on a :

```
6. 1101, 17. 592
5. 5277, 9. 1302
8. 5186, 13. 662
7. 0032, 11. 854
5. 8598, 6. 8233
8. 3829, 11. 886
7. 4764, 4. 3483
8. 5781, 12
6. 4862, 6. 5987
5. 0546, 3. 8166
5. 7107, 3. 2522
14. 164, 15. 505
5. 734, 3. 1551
8. 4084, 7. 2258
5. 6407, 0. 71618
```

Donc sur ces données, l'abscisse est la population d'une ville en dizaine de milliers d'habitants. L'ordonnée est le profit d'un camion de restauration dans cette ville en dizaine de milliers de dollars, le script ex1.m a déjà été mis en place pour charger ces données.

Donc on doit afficher tous les points dans un graph en régression linéaire, on calcule l'équation de la droite qui se rapproche le plus de ces données.

## 2. Linear regression with one variable


Le fichier ex1data1.txt contient l'ensemble de données pour notre problème de régression linéaire.

### 2.1 Plotting the Data

Et on affecte à X les valeurs de la première colonne et à Y les valeurs de la deuxième colonne. On a suivant :

```
1 function plotData(x, y)
2 %PLOTDATA Plots the data points x and y into a new figure
3 % PLOTDATA(x,y) plots the data points and gives the figure axes labels of
4 % population and profit.
5
6 % ===== YOUR CODE HERE =====
7 % Instructions: Plot the training data into a figure using the
8 % "figure" and "plot" commands. Set the axes labels using
9 % the "xlabel" and "ylabel" commands. Assume the
10 % population and revenue data have been passed in
11 % as the x and y arguments of this function.
12 %
13 % Hint: You can use the 'rx' option with plot to have the markers
14 % appear as red crosses. Furthermore, you can make the
15 % markers larger by using plot(..., 'rx', 'MarkerSize', 10);
16
17
18 plot(x,y,'rx','MarkerSize',10);
19 ylabel('Profit in $10,000s');
20 xlabel('Population of City in 10,000s');
21
22
23
24 % =====
25
26 end
```

Donc quand on finit le code dans le fichier plotData.m, on peut obtenir les données X et Y dans un graph avec les légendes des axes x et y (ylabel et xlabel) :



Le script qui s'appelle PlotData, ce script pour créer un diagramme de dispersion des données.

## 2.2 Gradient Descent

Dans ce parti, On arrive à la régression linéaire on peut obtenir suivant :

```

48 %% ===== Part 3: Gradient descent =====
49 fprintf('Running Gradient Descent ...\n')
50
51 X = [ones(m, 1), data(:,1)]; % Add a column of ones to x
52 theta = zeros(2, 1); % initialize fitting parameters
53
54 % Some gradient descent settings
55 iterations = 1500;
56 alpha = 0.01;
57
58 % compute and display initial cost
59 computeCost(X, y, theta)
60
61 % run gradient descent
62 theta = gradientDescent(X, y, theta, alpha, iterations);
63
64 % print theta to screen
65 fprintf('Theta found by gradient descent: ');
66 fprintf('%f %f \n', theta(1), theta(2));
67
68 % Plot the linear fit
69 hold on; % keep previous plot visible
70 plot(X(:,2), X*theta, '-')
71 legend('Training data', 'Linear regression')
72 hold off % don't overlay any more plots on this figure
73
74 % Predict values for population sizes of 35,000 and 70,000
75 predict1 = [1, 3.5] * theta;
76 fprintf('For population = 35,000, we predict a profit of %f\n', ...
77         predict1*10000);
78 predict2 = [1, 7] * theta;
79 fprintf('For population = 70,000, we predict a profit of %f\n', ...
80         predict2*10000);
81
82 fprintf('Program paused. Press enter to continue.\n');
83 pause;
84

```

## 2.2.1 Update Equations

On a cost fonction :

$$J(\theta) = \frac{1}{2m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Et on a hypothèse  $h(x)$  :

$$h_{\theta}(x) = \theta^T x = \theta_0 + \theta_1 x_1$$

Ce sont les valeurs que m'ajuster pour réduire au minimum le coût  $J(\theta)$ . Une façon de le faire est d'utiliser l'algorithme de descente de gradient de lot. Dans la descente gradient de lot, chaque itération effectue la mise à jour.

$$\theta_j := \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)} \quad (\text{simultaneously update } \theta_j \text{ for all } j).$$

A chaque étape de descente gradient, le paramètre  $\theta$  conduit le coût  $J(\theta)$  à un minimum.

On peut reconnaître la formule du gradient dans Octave :

```

1 function [theta, J_history] = gradientDescent(X, y, theta, alpha, num_iters)
2 %GRADIENTDESCENT Performs gradient descent to learn theta
3 %   theta = GRADIENTDESCENT(X, y, theta, alpha, num_iters) updates theta by
4 %   taking num_iters gradient steps with learning rate alpha
5
6 % Initialize some useful values
7 m = length(y); % number of training examples
8 J_history = zeros(num_iters, 1);
9
10 for iter = 1:num_iters
11
12     % ===== YOUR CODE HERE =====
13     % Instructions: Perform a single gradient step on the parameter vector
14     %                 theta.
15     %
16     % Hint: While debugging, it can be useful to print out the values
17     %         of the cost function (computeCost) and gradient here.
18     %
19
20
21     x = X(:,2);
22     h = theta(1) + (theta(2)*x);
23     theta0 = theta(1) - alpha * (1/m) * sum(h-y);
24     theta1 = theta(2) - alpha * (1/m) * sum((h - y) .* x);
25     theta = [theta0; theta1];
26
27
28
29     % =====
30
31     % Save the cost J in every iteration
32     J_history(iter) = computeCost(X, y, theta);
33
34 end
35
36 end
37

```

## 2.2.2 Implementation

Dans les lignes suivantes, nous ajoutons une autre dimension à nos données pour accueillir le terme  $\theta_0$  d'interception. On initialise également les paramètres initiaux à 0 et l'alpha taux d'apprentissage à 0,01.

## 2.2.3 Computing the cost $J(\theta)$

Lorsque on effectue la descente gradient pour apprendre minimiser la fonction de coût  $J(\theta)$ , on remplit le code dans le fichier `computeCost.m`, on a :

```

1 function J = computeCost(X, y, theta)
2 %COMPUTECOST Compute cost for linear regression
3 % J = COMPUTECOST(X, y, theta) computes the cost of using theta as the
4 % parameter for linear regression to fit the data points in X and y
5
6 % Initialize some useful values
7 m = length(y); % number of training examples
8
9 % You need to return the following variables correctly
10 J = 0;
11
12 % ===== YOUR CODE HERE =====
13 % Instructions: Compute the cost of a particular choice of theta
14 % You should set J to the cost.
15
16 predictions = X*theta;
17 sqrErrors = (predictions - y).^2;
18 J = 1/(2*m) * sum(sqrErrors);
19
20
21
22 % =====
23
24 end

```

Running warmUpExercise ...

5x5 Identity Matrix:

ans =

Diagonal Matrix

1	0	0	0	0
0	1	0	0	0
0	0	1	0	0
0	0	0	1	0
0	0	0	0	1

Program paused. Press enter to continue.

Plotting Data ...

Program paused. Press enter to continue.

Running Gradient Descent ...

ans = 32.073

Theta found by gradient descent: -3.630291 1.166362

For population = 35,000, we predict a profit of 4519.767868

For population = 70,000, we predict a profit of 45342.450129

Program paused. Press enter to continue.

## 2.4 Visualizing $J(\theta)$

Dans ce parti on a la programme suivant :

```


85 %% ===== Part 4: Visualizing J(theta_0, theta_1) =====
86 fprintf('Visualizing J(theta_0, theta_1) ...\n')
87
88 % Grid over which we will calculate J
89 theta0_vals = linspace(-10, 10, 100);
90 theta1_vals = linspace(-1, 4, 100);
91
92 % initialize J_vals to a matrix of 0's
93 J_vals = zeros(length(theta0_vals), length(theta1_vals));
94
95 % Fill out J_vals
96 for i = 1:length(theta0_vals)
97     for j = 1:length(theta1_vals)
98         t = [theta0_vals(i); theta1_vals(j)];
99         J_vals(i,j) = computeCost(X, y, t);
100     end
101 end
102
103
104 % Because of the way meshgrids work in the surf command, we need to
105 % transpose J_vals before calling surf, or else the axes will be flipped
106 J_vals = J_vals';
107 % Surface plot
108 figure;
109 surf(theta0_vals, theta1_vals, J_vals)
110 xlabel('\theta_0'); ylabel('\theta_1');
111
112 % Contour plot
113 figure;
114 % Plot J_vals as 15 contours spaced logarithmically between 0.01 and 100
115 contour(theta0_vals, theta1_vals, J_vals, logspace(-2, 3, 20))
116 xlabel('\theta_0'); ylabel('\theta_1');
117 hold on;
118 plot(theta(1), theta(2), 'rx', 'MarkerSize', 10, 'LineWidth', 2);
119

```

Après ces lignes sont exécutées, On crée une matrice de coût dans laquelle on rentre les valeurs de  $J(\theta)$  avec les numéros de ligne et de colonnes correspondant aux deux  $\theta$ .

Donc on a le graphe 3D avec les coordonnées  $\theta_0, \theta_1$  et  $J(\theta)$ , on a suivant :





Le but de ces graphiques est montrer  $J(\theta)$  avec les changements de  $\theta_0$  et  $\theta_1$ , On avoir les deux paramètres pour lesquels on a un coût minimum, ce minimum est le point optimal pour  $\theta_0$  et  $\theta_1$ , et chaque étape de descente gradient se rapproche de ce point.

